

Índice

Índice	1
1. Introducción	2
1.1 Contexto y definición del problema	2
1.2 Flujo de integración propuesto para la aseguradora	2
1.3 Alcance y limitación de validez externa	3
2. Trabajos relacionados y estado del arte	3
2.1 Clasificación automática de severidad: línea base y brecha de desempeño	3
2.2 Naturaleza ordinal de la severidad	4
2.3 Interpretabilidad y auditoría visual con Grad-CAM	4
2.5 Síntesis: brecha que aborda este trabajo	5
3. Objetivos	5
3.1 Objetivo general	5
3.2 Objetivos específicos	5
4. Metodología	5
4.1 Dataset y preparación de datos	6
4.2 Pipeline de preprocesamiento y aumento de datos	7
4.3 Arquitectura A: CNN desde cero	8
4.4 Arquitectura B: ResNet18 con Transfer Learning	8
4.5 Comparación de alternativas arquitectónicas	9
4.6 Estrategia de entrenamiento	10
4.7 Métricas de evaluación	11
4.8 Grad-CAM: implementación y protocolo de auditoría	11
5. Resultados	12
5.1 Distribución de clases y partición de datos	12
5.2 Parámetros de los modelos	12
5.3 Curvas de entrenamiento	12
5.4 Comparación cuantitativa de desempeño	13
5.5 Matrices de confusión	13
5.6 Auditoría cualitativa con Grad-CAM	14
6. Conclusiones y recomendaciones	16
6.1 Limitaciones	17
6.2 Recomendaciones	17

1. Introducción

1.1 Contexto y definición del problema

En el flujo operativo tradicional de una aseguradora, un supervisor revisa las fotografías del vehículo siniestrado para estimar la severidad del daño y aproximar el costo de reparación asociado. Si bien este procedimiento garantiza un criterio experto, resulta lento y constituye, en la práctica, el principal cuello de botella dentro del tiempo total de resolución de un siniestro (claim cycle time), afectando tanto la experiencia del asegurado como la eficiencia operativa de la compañía.

Frente a esta problemática, el presente trabajo propone y evalúa un clasificador automático de severidad de daños vehiculares (categorías minor, moderate y severe) a partir de imágenes fotográficas. Es importante precisar que el propósito del modelo no es sustituir el criterio del supervisor (ajustador), sino habilitar un esquema de triaje inteligente: enrutar automáticamente los casos de menor severidad hacia una aprobación rápida, y priorizar la revisión humana en los casos de severidad media o alta, donde el costo de un eventual error de clasificación es considerablemente mayor.

1.2 Flujo de integración propuesto para la aseguradora

Con el fin de situar el modelo dentro de un proceso de negocio concreto, la “Figura 1” esquematiza el flujo operativo propuesto para la integración del clasificador dentro del proceso de atención de siniestros de la aseguradora, desde la recepción de las fotografías hasta la validación final por parte del ajustador.




Figura 1. Flujo propuesto de integración del modelo de clasificación de severidad en el proceso de atención de siniestros de la aseguradora.

Como se observa en la Figura 1, el modelo actúa como una capa de decisión intermedia: los casos clasificados como menor se enrutan hacia una ruta de aprobación acelerada, mientras que los casos moderate y severe ingresan a una cola priorizada de revisión experta. La auditoría con Grad-CAM se ubica explícitamente antes del despliegue en producción, como una condición habilitante y no como un paso opcional posterior. Adicionalmente, se contempla un mecanismo de registro del resultado real de cada caso, que permite alimentar un proceso de monitoreo continuo y eventual reentrenamiento del modelo.

1.3 Alcance y limitación de validez externa

El dataset utilizado en este trabajo (disponible públicamente en Kaggle) contiene fotografías ya curadas y encuadradas hacia la zona de daño. En un escenario real de producción, las fotografías son tomadas por el propio cliente con su teléfono celular, presentando ángulos inconsistentes, fondos heterogéneos e iluminación deficiente. En consecuencia, el desempeño reportado en este trabajo debe interpretarse como un techo optimista de desempeño, y no como una estimación válida del desempeño esperado en un entorno de producción.

De manera análoga, es necesario delimitar el alcance funcional del modelo: este clasifica severidad, pero no localiza ni cuantifica el daño, ni estima directamente un costo de reparación. Se trata, por tanto, de un primer filtro de triage dentro del proceso, y no de un reemplazo integral del criterio del ajustador.

2. Trabajos relacionados y estado del arte

2.1 Clasificación automática de severidad: línea base y brecha de desempeño

La evaluación automática de daños vehiculares se consolidó como línea de investigación a partir de Patil et al. (2017), quienes descompusieron la tarea en tres clasificaciones sucesivas —presencia de daño, localización y severidad— y reportaron 89.5% de exactitud en la etapa de detección mediante transferencia y ensamblado de modelos. Kyu y Woraratpanya (2020) replicaron esa misma estructura con VGG16 y VGG19, publicando el desglose de desempeño por subtarea: 95.22% en detección, 76.48% en localización y solo 58.48% en severidad. Otros trabajos reportan cifras superiores bajo formulaciones distintas del problema: Widjojo et al. (2022) alcanzan un F1 de 91% al añadir como entrada la salida de un modelo de segmentación previo, mientras que Qaddour y Siddiqi (2023) integran las tres subtareas en una única arquitectura Mask R-CNN.

Conviene, sin embargo, delimitar el alcance real de estas cifras: proceden de conjuntos de datos, particiones y definiciones de clase heterogéneas entre sí, y ninguno de los trabajos revisados reporta intervalos de confianza. En consecuencia, las diferencias observadas entre arquitecturas no pueden atribuirse con seguridad al diseño del modelo en sí.

La caída de casi 37 puntos porcentuales entre detección y severidad dentro de un mismo estudio (Kyu y Woraratpanya, 2020) admite al menos tres explicaciones que la literatura revisada no logra discriminar entre sí: el paso de dos a tres clases, la mayor dificultad visual inherente a graduar una magnitud continua frente a simplemente detectar su presencia, o la ambigüedad propia del proceso de etiquetado, dado que ningún trabajo revisado documenta su procedimiento de anotación ni el nivel de acuerdo entre anotadores para la variable severidad. Esta última posibilidad resulta la de mayor consecuencia práctica, pues fijaría un techo de desempeño independiente del modelo

empleado; permanece, no obstante, sin verificar empíricamente, y el presente estudio tampoco la resuelve.

2.2 Naturaleza ordinal de la severidad

La variable objetivo de este problema posee una estructura ordinal explícita: las categorías minor, moderate y severe definen una escala en la que el costo de un error depende de la distancia entre la clase predicha y la clase real. La función de pérdida de entropía cruzada multicategoría no codifica dicha noción de distancia (Cao et al., 2020), y la literatura de regresión ordinal profunda ofrece alternativas ya consolidadas para abordar esta limitación, entre ellas el marco CORAL, que garantiza consistencia de rango mediante la compartición de pesos en la capa de salida (Cao et al., 2020), o los modelos de enlace acumulativo combinados con una función de pérdida derivada directamente del índice Kappa ponderado (Vargas et al., 2020).

Resulta notable que ninguno de los trabajos del dominio asegurador aquí revisados adopte formulaciones de este tipo, ni reporte métricas sensibles al orden de las clases. Podría objetarse que, si el sistema únicamente decide entre automatizar un caso o derivarlo a revisión humana, la distinción ordinal resultaría prescindible; sin embargo, el argumento pierde fuerza cuando la severidad predicha determina, además, la prioridad dentro de la cola de revisión —como ocurre en el flujo de negocio propuesto en este trabajo—. Debe advertirse, en contrapartida, que el uso del Kappa cuadrático presupone una penalización proporcional al cuadrado de la distancia entre clases, supuesto que no ha sido validado contra costos de reparación reales y que, por tanto, se adopta aquí como aproximación razonable y no como verdad empírica.

2.3 Interpretabilidad y auditoría visual con Grad-CAM

Grad-CAM (Selvaraju et al., 2020), generalización de los mapas de activación de clase propuestos originalmente por Zhou et al. (2016), constituye el método predominante para inspeccionar la evidencia visual en la que se apoya un clasificador convolucional. Su empleo se justifica por el riesgo de aprendizaje por atajos ("shortcut learning"): reglas de decisión eficaces sobre el conjunto de referencia empleado, pero que no transfieren a condiciones más exigentes o distintas (Geirhos et al., 2020) —riesgo particularmente plausible en fotografías donde el fondo, la marca del vehículo u otros elementos irrelevantes pueden correlacionar de forma espuria con la severidad real del daño.

El valor probatorio de Grad-CAM, no obstante, está lejos de ser incuestionable. Adebayo et al. (2018) mostraron que ciertos métodos de saliencia producen mapas insensibles tanto al modelo evaluado como a los datos de entrada, si bien Yona y Greenfeld (2021) replican ese hallazgo y sugieren que podría tratarse de un artefacto específico de las tareas evaluadas en el estudio original. Saporta et al. (2022), por su parte, hallaron que Grad-CAM, pese a superar a los otros seis métodos de interpretabilidad comparados en su estudio, localiza de forma significativamente más imprecisa que un anotador humano experto.

De ahí que una evaluación rigurosa de interpretabilidad demande, idealmente, métricas cuantitativas y que Rudin (2019) sostenga, de forma más radical, que en decisiones de alto riesgo debería preferirse directamente un modelo interpretable por diseño antes que una explicación post-hoc sobre un modelo de caja negra. Sobre esta base, el presente trabajo no pretende acreditar un modelo listo para despliegue sino caracterizar de forma diagnóstica dos arquitecturas bajo una métrica sensible al orden de las clases y una auditoría visual cuyas limitaciones se declaran de antemano, en lugar de presentarse como validación definitiva.

2.5 Síntesis: brecha que aborda este trabajo

La revisión anterior permite identificar tres vacíos recurrentes en la literatura sobre clasificación automática de severidad de daños vehiculares, que este trabajo busca abordar de forma explícita, aunque acotada: (i) la ausencia de métricas sensibles al orden de las clases, pese a que la variable severidad es inherentemente ordinal; (ii) la adopción de arquitecturas preentrenadas sin contrastarlas experimentalmente frente a alternativas entrenadas desde cero sobre el mismo dominio; y (iii) el uso de la interpretabilidad visual como recurso ilustrativo antes que como protocolo de auditoría con criterios explícitos y limitaciones declaradas. Los objetivos definidos en la siguiente sección responden directamente a estos tres vacíos, sin pretender resolverlos de manera definitiva: en particular, el presente trabajo no incorpora una formulación de regresión ordinal (como CORAL) ni métricas cuantitativas de localización para Grad-CAM, limitaciones que se retoman explícitamente en la sección de recomendaciones y trabajo futuro.

3. Objetivos

3.1 Objetivo general

Desarrollar y evaluar críticamente un modelo de clasificación de severidad de daños vehiculares a partir de imágenes, comparando una arquitectura convolucional entrenada desde cero con una arquitectura basada en transfer learning (ResNet18), e incorporando una auditoría de interpretabilidad mediante Grad-CAM que permita determinar la viabilidad de su integración en un flujo de triage de siniestros de una aseguradora.

3.2 Objetivos específicos

1. Definir y justificar el problema de clasificación de severidad de daños vehiculares como un problema de naturaleza ordinal, con implicancias directas sobre el costo de los errores desde la perspectiva del negocio asegurador.
2. Diseñar e implementar un pipeline de preparación de datos (partición estratificada, balanceo de clases y aumento de datos) adecuado para un dataset de tamaño reducido.
3. Construir, entrenar y comparar dos arquitecturas de red neuronal convolucional —una entrenada desde cero y otra basada en transfer learning sobre ResNet18— justificando las decisiones de diseño e hiperparámetros adoptadas en cada caso.
4. Evaluar cuantitativamente ambos modelos mediante métricas estándar (accuracy, F1-score por clase) y una métrica sensible al orden de las clases (Cohen's Kappa cuadrático).
5. Implementar Grad-CAM y aplicarlo como protocolo de auditoría cualitativa, con el fin de verificar si los modelos basan sus predicciones en evidencia visual relevante para el negocio.
6. Proponer un flujo de integración del modelo dentro del proceso operativo de una aseguradora, identificando limitaciones, riesgos y recomendaciones para un eventual despliegue.

4. Metodología

El desarrollo del presente trabajo siguió un proceso metodológico estructurado en siete etapas secuenciales, desde la adquisición de los datos hasta la decisión final de negocio, tal como se ilustra en la Figura 2. Cada etapa se describe en detalle en las secciones subsiguientes.




Figura 2. Proceso metodológico general seguido en el desarrollo del trabajo, desde la adquisición de datos hasta la decisión de negocio.

4.1 Dataset y preparación de datos

Se utilizó el Car Damage Severity Dataset, disponible públicamente en Kaggle (prajwalbhamere/car-damage-severity-dataset), organizado en carpetas training/ y validation/, cada una con subcarpetas minor/, moderate/ y severe/, cuyos prefijos numéricos preservan el orden ordinal de las clases. Se empleó el 100% de las imágenes disponibles en ambas carpetas, sin descartar ni sub muestrear ningún caso.

La Tabla 1 resume las principales características del dataset efectivamente utilizado, verificadas mediante la ejecución del notebook.

Tabla 1. Ficha descriptiva del dataset utilizado.

Atributo	Descripción
Fuente	Kaggle — prajwalbhamere/car-damage-severity-dataset
Tarea	Clasificación de severidad de daños vehiculares (imagen → clase)
Clases	minor (01), moderate (02), severe (03) — orden ordinal explícito
Estructura original	training/ y validation/, cada una con 3 subcarpetas de clase
Partición utilizada	training/ → entrenamiento · validation/ → dividido 50/50 (estratificado) en validación y test

Atributo	Descripción
N.º total de imágenes	1,631 imágenes (100% del dataset, sin submuestreo)
Partición train / val / test	1,383 / 124 / 124 imágenes respectivamente
Distribución por clase (train)	minor: 452 · moderate: 463 · severe: 468 — dataset prácticamente balanceado (32,7% / 33,5% / 33,8%)
Distribución por clase (val)	minor: 41 · moderate: 37 · severe: 46
Distribución por clase (test)	minor: 41 · moderate: 38 · severe: 45
Resolución de entrada al modelo	224 × 224 px (redimensionado desde 256 × 256 con recorte aleatorio en entrenamiento)
Formato de imagen	RGB (JPEG/PNG según archivo original)
Pesos de clase calculados	minor: 1.0199 · moderate: 0.9957 · severe: 0.9850 (cerca de 1.0, consistente con el balance casi perfecto del dataset)

Dado que el dataset original no incluye un conjunto de test independiente, la carpeta validation/ se particionó de forma estratificada (50/50) en subconjuntos de validación y de test. Esta decisión metodológica evita reportar las métricas finales sobre el mismo conjunto utilizado para el early stopping, lo cual introduciría un sesgo optimista silencioso en la evaluación del modelo.

A diferencia de lo que suele asumirse en datasets de daños vehiculares, la distribución de clases obtenida resultó casi perfectamente balanceada (452 / 463 / 468 imágenes por clase en entrenamiento), por lo que los pesos de clase calculados son cercanos a 1.0 en las tres categorías. En consecuencia, el mecanismo de compensación de desbalance —relevante en la formulación general del problema— tuvo en esta ejecución un efecto marginal sobre el entrenamiento.

4.2 Pipeline de preprocesamiento y aumento de datos

Se construyeron dos pipelines de preprocesamiento diferenciados, uno por arquitectura, en la medida en que cada uno responde a supuestos distintos sobre el origen de los pesos del modelo:

- **CNN desde cero:** normalización simple con media y desviación estándar de 0.5 en cada canal. No existe justificación para emplear las estadísticas de ImageNet, dado que el modelo no parte de pesos preentrenados sobre ese dominio.
- **ResNet18 (transfer learning):** normalización con las medias y desviaciones estándar de ImageNet (0.485/0.456/0.406 y 0.229/0.224/0.225), dado que el backbone preentrenado espera dicha distribución de entrada.

Asimismo, al CNN entrenado desde cero se le aplicó un aumento de datos más agresivo (recorte aleatorio, flip horizontal, rotación de hasta 15° y jitter de color) que al modelo con transfer learning. Esta diferencia responde a que, al no contar con el prior de ImageNet como regularizador implícito, resulta necesario compensar el riesgo de sobreajuste mediante una mayor diversidad artificial de ejemplos de entrenamiento. La Figura 3 ilustra seis variaciones sintéticas generadas a partir de una misma fotografía de entrenamiento, cada una vista por el modelo en una época distinta.

Data Augmentation -- clase real: severe (misma foto original, 6 variaciones sintéticas)



Figura 3. Seis variaciones sintéticas generadas por el pipeline de aumento de datos a partir de una misma imagen de entrenamiento (clase severe).

4.3 Arquitectura A: CNN desde cero

Se optó deliberadamente por finalizar la red con una capa de Global Average Pooling (GAP) en lugar de un bloque Flatten + Dense. Esta decisión de diseño no responde únicamente a un criterio de regularización sino a que esta arquitectura constituye, de acuerdo con el propio paper de Grad-CAM (Selvaraju et al., 2020, Sec. 3.1), el caso especial exacto de CAM: cuando el mapa de características pasa directamente por GAP hacia una capa lineal, los pesos de dicha capa resultan matemáticamente equivalentes a los pesos de importancia que Grad-CAM calcula mediante gradientes. Se trata, en consecuencia, de la arquitectura más consistente para auditar en qué se está fijando el modelo durante la etapa de interpretabilidad.

Tabla 2. Justificación de los hiperparámetros de la arquitectura CNN desde cero.

Elemento	Valor	Justificación
Bloques convolucionales	5 (32→64→128→256→512 canales)	Duplicar canales al reducir la resolución espacial es el patrón estándar para preservar capacidad representacional. El quinto bloque (256→512) iguala la resolución espacial final de ResNet18, permitiendo una comparación más justa entre ambas arquitecturas.
BatchNorm	Después de cada convolución	Sin pesos pre entrenados, la normalización por lotes resulta crítica para estabilizar el entrenamiento desde una inicialización aleatoria.
Dropout	0.5 antes de la capa final	Único punto de regularización fuerte, dado que no existe un prior de ImageNet que module implícitamente la capacidad del modelo.
GAP en vez de Flatten	—	Reduce el número de parámetros y el riesgo de sobreajuste, y habilita la compatibilidad matemática directa con CAM/Grad-CAM.
Parámetros totales	1,572,099	Arquitectura compacta: cerca de 7 veces menos parámetros que los entrenables de ResNet18 en su etapa final (ver Tabla 6).

4.4 Arquitectura B: ResNet18 con Transfer Learning

Como arquitectura de comparación se utilizó ResNet18 preentrenada sobre ImageNet. La capa fully-connected final se reemplazó por una nueva capa lineal con tres salidas, correspondientes a las clases minor, moderate y severe. A diferencia de un esquema de fine-tuning directo (descongelar todas las capas objetivo desde el inicio), en esta versión del trabajo se adoptó una estrategia de descongelamiento progresivo ("gradual unfreezing") en tres etapas secuenciales, práctica recomendada en la literatura de transfer learning para reducir el riesgo de "olvido catastrófico" de las representaciones preentrenadas cuando el dataset de destino es pequeño:

- **EtapA A — solo fc:** todas las capas convolucionales permanecen congeladas; únicamente se entrena la nueva capa lineal, permitiendo que esta se adapte inicialmente a las representaciones ya existentes del backbone sin distorsionarlas.
- **EtapA B — se descongela layer4:** se habilita el ajuste fino del último bloque residual (características de más alto nivel semántico), manteniendo el resto del backbone congelado.
- **EtapA C — se descongela adicionalmente layer3:** se amplía el ajuste fino a un segundo bloque residual, alcanzando la configuración final de la arquitectura, con conv1 y layer2 permanentemente congeladas por corresponder a características genéricas de bajo nivel, comunes a cualquier dominio de imágenes naturales.

Este enfoque progresivo permite que la capa final se estabilice antes de exponer las capas convolucionales pre entrenadas a gradientes potencialmente grandes, lo que resulta especialmente relevante dado el tamaño reducido del dataset (1,383 imágenes de entrenamiento).

4.5 Comparación de alternativas arquitectónicas

La Tabla 3 sintetiza los criterios considerados para comparar ambas arquitecturas, justificando por qué se optó por entrenar y evaluar ambas de forma paralela en lugar de seleccionar directamente una sola alternativa a priori.

Tabla 3. Comparación de las arquitecturas evaluadas.

Criterio	CNN desde cero	ResNet18 (Transfer Learning)
Origen de los pesos	Inicialización aleatoria	Preentrenados sobre ImageNet (1.28M imágenes)
Parámetros entrenables	1,572,099 (100% del modelo, arquitectura compacta de 5 bloques conv.)	10,494,979 / 11,178,051 en su etapa final C (93.9%); solo 1,539 (0.0%) en la etapa inicial A
Datos requeridos	Mayor cantidad, dado que aprende representaciones desde cero	Menor cantidad, al reutilizar representaciones visuales generales
Estrategia de ajuste	Entrenamiento completo en una sola fase (38 épocas efectivas)	Descongelamiento progresivo en 3 etapas (fc → +layer4 → +layer3), 12 épocas efectivas en total
Velocidad de convergencia observada	Convergencia gradual, estabilizada hacia la época 30 (val_loss ≈ 0.71)	Convergencia más rápida por etapa, con early stopping activándose en cada una (mejor val_loss ≈ 0.61 en fine-tuning directo inicial)

Criterio	CNN desde cero	ResNet18 (Transfer Learning)
Interpretabilidad / transparencia	Alta: arquitectura totalmente controlada y diseñada explícitamente para ser compatible con CAM	Media: arquitectura estándar de la literatura, con mayor profundidad y complejidad interna
Riesgo de sesgos heredados	Bajo, al no reutilizar pesos externos	Existe riesgo de heredar sesgos del dominio de origen (ImageNet)
Costo computacional de entrenamiento	Mayor número de épocas, menor costo por época	Menor número de épocas, mayor costo por época (red más profunda)
Ventaja distintiva	Mayor control y trazabilidad del proceso de aprendizaje	Aprovechamiento de conocimiento visual general transferido

Esta comparación explícita permite fundamentar la decisión final —documentada en la sección de Conclusiones— no solo en el desempeño cuantitativo agregado, sino también en criterios relevantes para el negocio, como la interpretabilidad y el riesgo de sesgos heredados en un sistema que puede afectar decisiones de pago de siniestros.

4.6 Estrategia de entrenamiento

Ambos modelos se entrenaron con el optimizador AdamW, empleando un scheduler ReduceLROnPlateau —que reduce la tasa de aprendizaje al estancarse la pérdida de validación— y early stopping basado en dicha pérdida, con el fin de mitigar el sobreajuste y preservar el mejor checkpoint en cada fase de entrenamiento. La Tabla 4 resume los hiperparámetros efectivamente utilizados para el CNN desde cero, entrenado en una sola fase.

Tabla 4. Hiperparámetros de entrenamiento — CNN desde cero.

Hiperparámetro	Valor	Resultado observado
Learning rate / weight decay	5e-4 / 1e-4 (AdamW, único para todos los pesos)	Convergencia estable, sin oscilaciones abruptas
Épocas máximas / patience	40 / 8	Early stopping activado en la época 38
Función de pérdida	CrossEntropyLoss (sin ponderación explícita de clase)	val_loss final ≈ 0.712 · val_acc final ≈ 0.71

La Tabla 5 resume, por su parte, los hiperparámetros de cada una de las tres etapas del fine-tuning progresivo de ResNet18, así como el número de épocas efectivamente ejecutadas antes de la activación del early stopping en cada etapa.

Tabla 5. Hiperparámetros de entrenamiento por etapa — ResNet18 (fine-tuning progresivo).

Etapas	Capas entrenables / LR	Épocas máx. / ejecutadas	Resultado observado
A	fc — LR 1e-3	4 / 4 (sin early stopping)	val_loss: 0.867 → 0.786

Etapa	Capas entrenables / LR	Épocas máx. / ejecutadas	Resultado observado
B	layer4 (1e-4) + fc (5e-4)	6 / 4 (early stopping)	mejor val_loss $\approx$ 0.698 (época 2)
C	layer3 (1e-4) + layer4 (1e-4) + fc (1e-3)	15 / 4 (early stopping)	mejor val_loss $\approx$ 0.691 (época 1); checkpoint final del modelo

En conjunto, ResNet18 completó 12 épocas efectivas de entrenamiento (4 + 4 + 4) frente a las 38 del CNN desde cero, lo cual, sumado a la reutilización de representaciones preentrenadas, se tradujo en un número considerablemente menor de "vistas" de entrenamiento generadas por aumento de datos: 16,596 frente a 52,554 (1,383 imágenes $\times$ épocas efectivas de cada modelo).

4.7 Métricas de evaluación

El desempeño de ambos modelos se evaluó sobre el conjunto de test independiente mediante los siguientes indicadores:

- **Accuracy y F1-score por clase:** métricas estándar de clasificación, reportadas mediante la función `classification_report` de scikit-learn.
- **Matriz de confusión:** con especial atención a las celdas de esquina (minor predicho como severe, o viceversa), correspondientes a los errores ordinales de mayor costo para el negocio.
- **Cohen's Kappa cuadrático:** propuesto en este trabajo como métrica principal de decisión de negocio, en la medida en que penaliza en mayor grado los errores "lejanos" en la escala ordinal minor–moderate–severe. Entre dos modelos con accuracy similar, aquel con mayor Kappa cuadrático incurre en errores comparativamente más "baratos" para la aseguradora.

4.8 Grad-CAM: implementación y protocolo de auditoría

Se implementó Grad-CAM desde cero (Selvaraju et al., 2020, Ec. 1-2), enganchado a la última capa convolucional de cada arquitectura, de manera reutilizable para ambos modelos. El mapa de calor se obtiene promediando globalmente los gradientes de la clase predicha respecto a los mapas de activación (Ec. 1), realizando posteriormente una combinación lineal ponderada seguida de una función ReLU (Ec. 2), e interpolando el resultado al tamaño original de la imagen.

El protocolo de auditoría de negocio aplicado sobre los casos de test comprende tres verificaciones principales:

- Verificar, en los casos correctamente clasificados por ambos modelos, si el heatmap se concentra en la zona real de daño (abolladura, rayón, cristal roto) —señal de una representación útil— o en el fondo, el logo de la marca o la placa —señal de correlación espuria.
- En los casos mal clasificados, distinguir errores "de grado" (el modelo observaba la zona de daño correcta pero subestimó su severidad) de errores "de lugar equivocado" (el modelo no observaba el daño en absoluto), siendo estos últimos considerablemente más graves para el negocio.
- Comparar la nitidez y el foco de los mapas Grad-CAM entre ambas arquitecturas en los casos donde coinciden en la predicción, como criterio adicional de confiabilidad, replicando el enfoque de evaluación de confianza propuesto en el paper original.

5. Resultados

Esta sección presenta las salidas obtenidas de la ejecución completa del notebook actualizado: distribución final de los datos, parámetros de ambos modelos, curvas de entrenamiento, métricas cuantitativas sobre el conjunto de test y la auditoría cualitativa mediante Grad-CAM.

5.1 Distribución de clases y partición de datos

La ejecución del notebook confirmó un total de 1,631 imágenes, distribuidas en 1,383 para entrenamiento, 124 para validación y 124 para test, de acuerdo con el detalle ya presentado en la Tabla 1 (sección 3.1). La distribución de clases en el conjunto de entrenamiento resultó casi perfectamente balanceada (452 minor / 463 moderate / 468 severe), por lo que los pesos de clase calculados se ubicaron todos muy cerca de 1.0 (minor: 1.0199, moderate: 0.9957, severe: 0.9850).

5.2 Parámetros de los modelos

Tabla 6. Comparación del número de parámetros por modelo.

Modelo	Parámetros entrenables	% del total
CNN desde cero	1,572,099 / 1,572,099	100%
ResNet18 — etapa inicial (A)	1,539 / 11,178,051	0.0%
ResNet18 — etapa final (C)	10,494,979 / 11,178,051	93.9%

El contraste es ilustrativo: en su etapa inicial, ResNet18 ajusta apenas 1,539 parámetros (solo la capa fc), mientras que el CNN desde cero entrena la totalidad de su arquitectura, considerablemente más compacta, desde la primera época.

5.3 Curvas de entrenamiento

La Figura 4 muestra la evolución de la pérdida y el accuracy de validación para ambos modelos. Para ResNet18, la curva corresponde a la etapa final (C) del fine-tuning progresivo, la más relevante para la evaluación final.




Figura 4. Curvas de Val Loss y Val Accuracy por época — CNN desde cero (38 épocas) vs. ResNet18, etapa C de fine-tuning (4 épocas).

El CNN desde cero exhibe una convergencia gradual y estable: el val_loss desciende de forma sostenida desde 1.19 hasta estabilizarse alrededor de 0.71 hacia la época 30, sin señales claras de sobreajuste severo, y el early stopping se activa recién en la época 38. ResNet18, en cambio,

converge mucho más rápido pero exhibe mayor varianza entre épocas dentro de cada etapa (por ejemplo, un salto de `val_loss` de 0.69 a 1.04 entre las épocas 1 y 2 de la etapa C), reflejo de la sensibilidad del ajuste fino a tasas de aprendizaje relativamente altas sobre un conjunto de validación pequeño (124 imágenes). El early stopping se activó en la etapa C tras solo 4 épocas, preservando el checkpoint de la época 1 (`val_loss` $\approx$ 0.691), el de menor pérdida de validación alcanzado en dicha etapa.

5.4 Comparación cuantitativa de desempeño

La Tabla 7 resume las métricas obtenidas por ambos modelos sobre el conjunto de test independiente (124 imágenes).

Tabla 7. Comparación de métricas de desempeño sobre el conjunto de test.

Modelo	Accuracy	F1 minor	F1 moderate	F1 severe	Kappa (cuadr.)
CNN desde cero	0.58	0.69	0.34	0.68	0.6605
ResNet18 (TL)	0.66	0.73	0.43	0.77	0.7162

ResNet18 supera al CNN desde cero en todas las métricas reportadas: +8 puntos porcentuales de accuracy, mejor F1 en las tres clases, y un Kappa cuadrático notoriamente superior (0.7162 frente a 0.6605). En ambos modelos, la clase moderate es sistemáticamente la más difícil de predecir (F1 de apenas 0.34 y 0.43 respectivamente), lo cual es consistente con su posición intermedia en la escala ordinal: visualmente, el límite entre "daño leve" y "daño moderado", o entre "moderado" y "severo", es inherentemente más ambiguo que el límite entre los extremos minor y severe.

5.5 Matrices de confusión

La Figura 5 presenta las matrices de confusión de ambos modelos sobre el conjunto de test.




Figura 5. Matrices de confusión sobre el conjunto de test — CNN desde cero (izquierda) y ResNet18, TL (derecha).

El análisis de las celdas de esquina (minor↔severe), correspondientes a los errores ordinales de mayor costo para el negocio, revela un hallazgo que matiza la comparación de la Tabla 7: el CNN desde cero incurrió en 2 casos de minor clasificado como severe y 0 casos de severe clasificado como minor (2 errores de esquina en total), mientras que ResNet18 incurrió en 1 caso de

menor→severe y 2 casos de severe→menor (3 errores de esquina en total). Es decir, pese a tener mejor accuracy, F1 y Kappa cuadrático agregados, ResNet18 clasificó 2 casos realmente severos como menor —el tipo de error más peligroso para una aseguradora, ya que podría traducirse en la aprobación automática de un siniestro grave—, mientras que el CNN desde cero no cometió ningún error de esa naturaleza en el conjunto de test evaluado.

Este resultado ilustra por qué el Kappa cuadrático agregado, aunque más informativo que el accuracy, no sustituye por completo la inspección directa de la matriz de confusión: dos modelos con Kappa distinto pueden aun así presentar patrones de error cualitativamente distintos y relevantes para el negocio. En ambos modelos, la clase moderate concentra la mayor dispersión de errores (17 casos moderate→severe en el CNN; 16 casos moderate→menor en ResNet18), confirmando la dificultad ya señalada en la sección 4.4.

5.6 Auditoría cualitativa con Grad-CAM

Con base en el protocolo descrito en la sección 3.8, se aplicó Grad-CAM sobre casos correctamente clasificados y sobre casos mal clasificados del CNN desde cero.

Caso correctamente clasificado por ambos modelos

La Figura 6 muestra un caso real severe correctamente clasificado por ambas arquitecturas, permitiendo comparar directamente la calidad de sus mapas de atención.




Figura 6. Grad-CAM — CNN desde cero sobre un caso severe correctamente clasificado (confianza 41.31%).




Figura 7. Grad-CAM — ResNet18 (TL) sobre la misma imagen (confianza 72.49%).

En ambos casos el heatmap se concentra correctamente sobre la zona de daño real (el lateral frontal izquierdo del vehículo), sin evidencia de atención hacia el fondo o elementos irrelevantes de la imagen. El mapa de ResNet18 resulta visiblemente más compacto y localizado que el del CNN desde cero, y su confianza en la predicción correcta es sustancialmente mayor (72.49% frente a

41.31%). Este patrón es consistente con lo esperado: el backbone preentrenado de ResNet18 aporta representaciones visuales más discriminativas, lo que se traduce no solo en mejores métricas agregadas, sino también en mapas de interpretabilidad más nítidos.

Casos mal clasificados (CNN desde cero)

Las Figuras 8 a 10 documentan tres casos mal clasificados por el CNN desde cero, seleccionados para ilustrar los dos tipos de error definidos en el protocolo de auditoría de la sección 3.8.




Figura 8. Caso real severe predicho como moderate (53.07%). El heatmap se concentra en la cajuela abierta y el paragolpes trasero, zonas efectivamente dañadas: error "de grado" (zona correcta, severidad subestimada).




Figura 9. Caso real minor predicho como moderate (41.39%). El heatmap se dispersa sobre vehículos del fondo y el techo/parabrisas, sin anclarse en un daño visible: posible error "de lugar equivocado", y una señal de alerta para la auditoría de negocio.




Figura 10. Caso real severe predicho como moderate (41.71%). El heatmap se concentra con precisión sobre el capó y faro delantero colapsados: error "de grado" (zona correcta, severidad subestimada).

De los tres casos mal clasificados analizados, dos corresponden a errores "de grado" (Figuras 8 y 10): el modelo identifica correctamente la región dañada del vehículo, pero subestima su severidad real, un tipo de error comprensible y de menor riesgo para el negocio. El caso de la Figura 9 es más

preocupante desde la perspectiva de auditoría: al tratarse de una imagen sin daño visible evidente (clase real minor), el modelo dirige su atención hacia vehículos del fondo de la escena en lugar de hacia el vehículo de interés, lo cual constituye evidencia de un posible error "de lugar equivocado" y sugiere que, en imágenes de baja severidad o sin daño claramente visible, el CNN desde cero puede apoyarse en información contextual poco confiable. Se recomienda ampliar esta auditoría a una muestra mayor de los 52 casos mal clasificados por el CNN (de un total de 124 evaluados) antes de emitir una conclusión definitiva sobre este patrón.

6. Conclusiones y recomendaciones

- De acuerdo con los resultados de la sección 4, ResNet18 (transfer learning con fine-tuning progresivo) superó de forma consistente al CNN desde cero en todas las métricas agregadas: accuracy (0.66 vs. 0.58), F1 en las tres clases, y Kappa cuadrático (0.7162 vs. 0.6605). Considerando además que ResNet18 alcanzó estos resultados con apenas 12 épocas efectivas de entrenamiento frente a las 38 del CNN desde cero, el costo de entrenamiento relativo favorece claramente a la arquitectura con transfer learning, confirmando la expectativa planteada en la Tabla 3 (sección 3.5).
- Sin embargo, esta conclusión debe matizarse con el hallazgo de la sección 4.5: al inspeccionar la matriz de confusión, el CNN desde cero no cometió ningún error de clasificar un caso severe como minor, mientras que ResNet18 cometió dos. Dado que este tipo de error es el más costoso desde la perspectiva de negocio planteada en la Introducción (sección 1.3), la elección del modelo "ganador" no debería basarse únicamente en las métricas agregadas de la Tabla 6, sino también en el análisis desagregado de los errores de esquina. En este trabajo, ResNet18 se considera la mejor opción global por su desempeño superior en las tres métricas y clases, pero se recomienda monitorear específicamente la tasa de errores severe→minor si el modelo llegase a desplegarse.
- La auditoría Grad-CAM (sección 4.6) mostró que, en el caso correctamente clasificado por ambos modelos, tanto el CNN desde cero como ResNet18 concentraron su atención en la zona real de daño, sin evidencia de correlaciones espurias evidentes (fondo, marca, placa). Esto brinda una señal de confianza básica sobre el comportamiento de ambos modelos, más allá de sus métricas agregadas. No obstante, uno de los tres casos mal clasificados analizados (Figura 9) mostró al CNN desde cero dirigiendo su atención hacia vehículos del fondo de la imagen en un caso sin daño visible evidente, lo cual constituye una señal de alerta que amerita ampliar la auditoría antes de cualquier consideración de despliegue.
- En términos de desempeño por clase, ambos modelos presentan su punto más débil en la clase moderate (F1 de 0.34 en el CNN y 0.43 en ResNet18), consistentemente con su posición intermedia en la escala ordinal: la frontera visual entre "daño leve" y "daño moderado", o entre "moderado" y "severo", es inherentemente más ambigua que la frontera entre los extremos. Este patrón sugiere que, en un eventual despliegue, los casos predichos como moderate deberían recibir sistemáticamente revisión humana adicional, independientemente del modelo elegido (recomendación que ya está contemplada en el flujo de negocio propuesto en la Figura 1)

- Respecto a si alguno de los dos modelos resulta "desplegable" en su estado actual: ninguno alcanza un nivel de desempeño que permita prescindir de la revisión humana en los casos moderate/severe. El accuracy de ambos modelos (0.58 y 0.66) es, en el mejor de los casos, moderado, y el tamaño del conjunto de test (124 imágenes, 38-46 por clase) limita la robustez estadística de las conclusiones. En consecuencia, el modelo actual es apto como apoyo al triage inicial (fast-track de los casos minor con mayor confianza), pero no para la toma de decisiones autónoma sobre el pago de un siniestro.

6.1 Limitaciones

- **Validez externa del dataset:** las imágenes utilizadas se encuentran curadas y encuadradas hacia el daño, a diferencia de fotografías tomadas por clientes reales, que presentan ángulos inconsistentes, fondos variables e iluminación deficiente. El desempeño reportado constituye, por tanto, un techo optimista y no una estimación de desempeño en producción.
- **Tamaño del conjunto de test:** 124 imágenes (38-46 por clase) constituyen una muestra reducida para estimar con precisión estadística métricas como el F1 por clase, especialmente en la clase moderate, donde ambos modelos concentran su mayor tasa de error. Diferencias de pocos puntos porcentuales entre modelos deben interpretarse con cautela.
- **Inconsistencia menor en el pipeline de datos:** como se señaló en la sección 3.6, el código hace referencia a un mecanismo de muestreo balanceado (WeightedRandomSampler) que no se encuentra efectivamente implementado; su impacto fue limitado en esta ejecución porque el dataset resultó casi perfectamente balanceado, pero representa un punto a corregir antes de reutilizar el pipeline sobre datos con mayor desbalance.
- **Alcance de la formulación del problema:** el modelo clasifica severidad, pero no localiza ni cuantifica el daño, ni estima un costo de reparación. Constituye un primer filtro de triage dentro del proceso, y no un reemplazo del ajustador humano.
- **Ausencia de un conjunto de test independiente original:** al particionar la carpeta validation/ en subconjuntos de validación y test, el tamaño de cada uno resulta menor al que se obtendría con una partición de tres conjuntos definida desde el origen del dataset, lo que puede afectar la estabilidad estadística de las métricas reportadas.

6.2 Recomendaciones

- Se recomienda ampliar la auditoría Grad-CAM a una muestra más amplia de los 52 casos mal clasificados por el CNN desde cero (y a los casos análogos de ResNet18), con el fin de cuantificar con mayor precisión la proporción de errores "de lugar equivocado" frente a errores "de grado".
- Ejecutar el experimento de ablación sugerido durante el desarrollo del notebook: reentrenar el CNN desde cero sin aumento de datos (usando únicamente Resize + ToTensor + Normalize) y comparar su curva de val_loss contra la versión con aumento de datos, como evidencia empírica directa de que la técnica efectivamente reduce el sobreajuste en este dataset.
- Corregir la inconsistencia entre los comentarios del código y la implementación real señalada en la sección 3.6 (ausencia de WeightedRandomSampler), e incorporar dicho mecanismo de forma explícita si se reentrena el modelo sobre un dataset con mayor desbalance de clases que el utilizado en este trabajo.
- Evaluar la incorporación de imágenes no curadas, tomadas directamente por clientes, con el objetivo de estimar de forma más realista el desempeño esperado en producción y, de ser necesario, reentrenar o ajustar el modelo sobre ese dominio.
- Explorar la reformulación del problema como una tarea de regresión ordinal —por ejemplo, mediante CORAL loss— en lugar de clasificación categórica estándar, dado que este enfoque respeta de forma nativa el orden minor < moderate < severe y podría reducir aún más la incidencia de errores ordinales costosos, incluyendo los errores severe→minor identificados en la sección 4.5.

- En una fase posterior, extender el sistema hacia tareas de localización y cuantificación del daño, con el fin de aproximarse a una estimación automática del costo de reparación, en línea con el flujo de negocio propuesto en la Figura 1.