

Clasificación de severidad de daños vehiculares

CNN desde cero + Transfer Learning, auditados con Grad-CAM

Clasificación automática de daños en minor, moderate y severe para apoyar el triage de siniestros, incorporando Grad-CAM como mecanismo de auditoría.

UNIVERSIDAD ESAN

Diploma de Especialización en Data Analytics · Curso: Deep Learning · Prof. Javier Zárate

Cesar Augusto Romero Aranda
Katuska [Apellido]
Germán Rodrigo Guerra Wiegmann
Esteban [Apellido]
Emmil Parras Salinas

Triage manual de siniestros: el cuello de botella del negocio

SITUACIÓN ACTUAL


- El ajustador revisa individualmente las fotografías del vehículo.
- Todos los casos ingresan a un flujo similar, aunque tengan diferente severidad.
- La clasificación inicial consume tiempo y retrasa la priorización.
- La evaluación depende de la revisión humana caso por caso.

PROPUESTA

- Un modelo clasifica el daño como menor, moderate o severe.
- Minor: candidato a una ruta de revisión rápida.
- Moderate/Severe: prioridad para evaluación humana.
- Grad-CAM muestra qué zona influyó en la predicción.
- El ajustador conserva la decisión final.



Fotografía del siniestro



Modelo IA Deeplearning



Nivel de Severidad




Prioridad de Atención

Un modelo con buen accuracy pero decisiones no auditables es un riesgo de negocio inaceptable en seguros.

02 LOS DATOS

Car Damage Severity Dataset (Kaggle) — 1,631 imágenes en total



1,383


imágenes de
entrenamiento

248


imágenes val/test (124
c/u, split estratificado)

Limitación clave

Fotos curadas y bien encuadradas. Una foto real de cliente (fondo, ángulo, luz) es más difícil — techo optimista, no desempeño de producción.



Minor





Moderate



Severe

03 METODOLOGÍA



Data Augmentation

Redimensionamiento a 256×256 y recorte aleatorio a 224×224 , rotación de $\pm 15^\circ$, flip horizontal y variaciones de brillo, contraste y saturación. Reduce el sobreajuste.

Cross-Entropy Ponderada



Los lotes se mezclan con `shuffle=True`. Los pesos de clase se incorporan en la función de pérdida para reducir posibles sesgos.

Transfer Learning + Fine-tuning parcial

Se utilizó ResNet18 preentrenada. Las capas iniciales se congelaron y se ajustaron layer3, layer4 y fc con tasas de aprendizaje diferenciadas.

04 ARQUITECTURA

CNN desde cero vs. ResNet18 con Transfer Learning




¿Por qué Global Average Pooling y no Flatten+Dense?

GAP resume cada mapa de características en un valor por canal, reduce parámetros y limita el sobreajuste. Además, facilita una relación directa entre las características aprendidas y la explicación mediante CAM/Grad-CAM.

¿Por qué un quinto bloque convolucional?

El bloque 256 → 512 reduce el mapa final a 7 × 7, igualando la resolución espacial de ResNet18. Esto permite comparar los mapas Grad-CAM de ambas arquitecturas bajo condiciones más equivalentes.

05 EXPLICABILIDAD — GRAD-CAM



¿Qué nos permite auditar Grad-CAM?

Visualiza las regiones de la imagen que más influyeron en la predicción, permitiendo verificar si el modelo se apoya en el daño real o en elementos irrelevantes del entorno

1

Gradientes: Se calculan los gradientes de la clase predicha respecto a los mapas de activación.

2

Pesos α : Se promedian globalmente los gradientes para obtener la importancia de cada canal.

3

Combinación + ReLU : Los mapas se combinan según esos pesos y se conservan las regiones con influencia positiva.

4

Reescalado : El mapa resultante se interpola al tamaño de la imagen original para generar el overlay.

LEYENDA DEL HEATMAP:



zona que más influyó en la predicción del modelo.



Influencia intermedia.



zona que influyó mucho en la predicción del modelo.





Poca o casi ninguna influencia.

Una predicción correcta no es suficiente si el modelo está mirando el lugar equivocado.

Sin el ReLU, el error de localización empeora ~15% (Selvaraju et al., 2020) porque se mezclan regiones que sustentan OTRAS clases, no la predicha.

06 RESULTADOS

ResNet18 mejora el desempeño global, pero mantiene errores críticos para el negocio



Hallazgo clave: ResNet18 logra el mejor desempeño global (Accuracy 66.1%; Kappa cuadrático 0.716), pero clasifica 2 casos severe como minor. Por ello, las métricas agregadas no son suficientes para evaluar el riesgo del modelo.

⚠ Error crítico para el negocio: Severe → Minor

07 AUDITORÍA DE NEGOCIO

Checklist de auditoría pre-despliegue: aún existen señales de alerta

Mayormente Sí

¿Mira el daño real?


En el caso correctamente clasificado, CNN y ResNet18 concentraron la atención sobre el daño. Además, 2 de los 3 errores revisados de la CNN mantuvieron la atención en la zona dañada.



1 SEÑAL DETECTADA

¿Correlaciones espurias?


En 1 de los 3 errores analizados, la CNN dirigió su atención hacia vehículos del fondo en lugar del vehículo de interés.



2 DE 3 CASOS

¿Errores razonables?

Dos errores fueron “de grado severo”: el modelo identificó la zona dañada, pero estimó incorrectamente su severidad clasificándolo como moderado.



PENDIENTE

¿Auditoría exhaustiva?

Se auditó un caso correctamente clasificado por ambos modelos y 3 casos mal clasificados de la CNN. La muestra aún es insuficiente para generalizar.



Conclusión: Apto como apoyo al triage, pero no para decisiones autónomas. Se requiere ampliar la validación Grad-CAM y monitorear errores críticos antes de producción.

08 CONCLUSIONES Y TRABAJO FUTURO

Principales conclusiones

- ResNet18 obtuvo el mejor desempeño global: 66.1% de Accuracy y Kappa cuadrático de 0.716, superando a la CNN desde cero.
- La clase moderate fue la más difícil para ambos modelos, evidenciando el reto de distinguir niveles intermedios de severidad.
- La naturaleza ordinal importa: los errores deben analizarse según su distancia y su impacto, no únicamente mediante Accuracy.
- Grad-CAM aportó una capa de auditoría: permitió distinguir errores de grado de errores de localización y detectar al menos una señal de atención fuera del vehículo objetivo.
- El modelo aún requiere supervisión humana, especialmente ante predicciones ambiguas o de alto impacto.

Trabajo futuro — próximas etapas

1. Validación más robusta
Multi-semilla y k-fold para reducir dependencia de un único split de test.
2. Mayor generalización
Validar con fotografías reales de clientes, con variaciones de iluminación, fondo y ángulo.
3. Modelo más seguro
Definir umbrales de confianza y abstención para derivar casos ambiguos a revisión humana.
4. Mejorar el enfoque ordinal
Evaluar métodos específicos como CORAL y ampliar la auditoría sistemática con Grad-CAM.

Gracias